

DAFTAR ISI

BAB I EXPLORASI KONSEP	2
1.1. Apa itu EDA?	2
1.2. Posisi EDA dalam Alur Proyek Machine Learning	3
1.3. Perbedaan EDA, Data Cleaning, dan Preprocessing	4
1.4. Peran EDA dalam menentukan Algoritma Machine Learning	5
BAB II ENSIKLOPEDIA FUNGSI EDA	7
2.1 Pengecekan Struktur dan Kondisi Data	7
2.2 Statistik dan Distribusi	8
2.3 Missing Value dan Data Quality	9
2.4 Visualisasi	10
2.5 Statistik Lanjutan dan Preprocessing untuk Eksplorasi	12

BAB I

EXPLORASI KONSEP

1.1. Apa itu EDA?

Exploratory Data Analysis (EDA) adalah proses eksplorasi dan penyelidikan terhadap suatu kumpulan data untuk memahami karakteristik, pola, hubungan, distribusi, serta kemungkinan masalah yang terdapat di dalam data sebelum dilakukan proses analisis lebih lanjut atau pembangunan model Machine Learning.

Konsep EDA diperkenalkan dan dipopulerkan oleh John W. Tukey, seorang ahli statistik dari Amerika Serikat. Tukey memperkenalkan EDA sebagai pendekatan yang menekankan pentingnya mengeksplorasi data terlebih dahulu sebelum membuat kesimpulan atau membangun model.

EDA dapat dianggap sebagai sebuah filosofi dalam memahami data. Data tidak langsung digunakan untuk membuat model, tetapi terlebih dahulu "diinterogasi" untuk mengetahui apa yang sebenarnya terdapat di dalamnya.


Dalam EDA, seorang data scientist dapat mencari informasi seperti:

1. Apakah terdapat data yang kosong?
2. Apakah terdapat data duplikat?
3. Bagaimana distribusi setiap variabel?
4. Apakah terdapat nilai yang terlalu ekstrem atau outlier?
5. Apakah terdapat hubungan antarvariabel?
6. Apakah terdapat pola tertentu?
7. Apakah data memiliki ketidakseimbangan kelas?
8. Apakah terdapat kesalahan atau keanehan dalam data?

Dengan demikian, **EDA bukan sekadar membuat grafik**, tetapi merupakan proses untuk memperoleh pemahaman terhadap data sehingga keputusan pada tahap berikutnya dapat dilakukan berdasarkan kondisi data yang sebenarnya.

1.2. Posisi EDA dalam Alur Proyek Machine Learning

Secara umum, EDA dapat ditempatkan dalam alur proyek Machine Learning sebagai berikut:



Mengapa EDA dilakukan sebelum membersihkan data?

EDA dilakukan terlebih dahulu agar kita mengetahui kondisi dan karakteristik data sebelum menentukan tindakan pembersihan.

Contohnya, ketika menemukan missing value, kita tidak seharusnya langsung menghapus seluruh baris yang memiliki nilai kosong. Melalui EDA, kita dapat mengetahui:

1. Berapa banyak missing value?
2. Kolom mana yang memiliki missing value?
3. Apakah missing value tersebar secara acak?
4. Apakah terdapat pola tertentu?
5. Apakah penghapusan data akan menyebabkan kehilangan informasi penting?

Dengan memahami kondisi tersebut, metode cleaning yang digunakan dapat lebih tepat. Sehingga, EDA membantu kita memahami masalah pada data, sedangkan Data Cleaning merupakan tindakan untuk menangani masalah tersebut.

1.3. Perbedaan EDA, Data Cleaning, dan Preprocessing

Aspek	EDA	Data Cleaning	Preprocessing
Tujuan	Memahami data	Memperbaiki masalah/kotoran pada data	Mempersiapkan data untuk algoritma
Fokus	Pola, distribusi, hubungan, anomali	Missing value, duplikat, kesalahan data	Scaling, encoding, transformasi
Pertanyaan utama	"Apa yang terjadi pada data?"	"Bagaimana memperbaiki data yang bermasalah?"	"Bagaimana mengubah data agar siap digunakan model?"
Contoh	Histogram, korelasi, boxplot	Menghapus duplikat, menangani null	StandardScaler, One-Hot Encoding
Output	Pemahaman/insight	Data lebih bersih	Data siap digunakan algoritma

Contoh fungsi	describe(), corr(), histplot()	dropna(), drop_duplicates()	get_dummies(), pd.cut()
---------------	--------------------------------	-----------------------------	-------------------------

Secara sederhana, **EDA** berfungsi untuk **memahami data**. Misalnya menggunakan histogram untuk melihat distribusi data atau boxplot untuk melihat kemungkinan adanya outlier.

Data Cleaning berfungsi untuk membersihkan data yang bermasalah, misalnya untuk menangani data yang kosong atau menghapus data duplikat.

Preprocessing merupakan tahap mengubah data menjadi bentuk yang sesuai untuk algoritma Machine Learning.

1.4. Peran EDA dalam menentukan Algoritma Machine Learning

EDA dapat membantu menentukan pendekatan Machine Learning karena karakteristik data yang ditemukan selama eksplorasi dapat memengaruhi metode yang sesuai. Beberapa contoh karakteristik data yang bisa ditemukan selama eksplorasi adalah:

1. Hubungan data linear

Jika hasil eksplorasi menunjukkan bahwa hubungan antara variabel independen dan target cenderung linear, maka metode seperti Linear Regression dapat menjadi salah satu pendekatan yang dipertimbangkan.

2. Banyak outlier

Jika EDA menemukan banyak outlier, algoritma tertentu yang sensitif terhadap jarak dapat terpengaruh. Salah satu contoh adalah K-Nearest Neighbors (K-NN) yang menggunakan jarak antar data. Outlier dapat memengaruhi perhitungan jarak tersebut.

Dalam kondisi tertentu, model berbasis pohon seperti Decision Tree atau Random Forest dapat menjadi alternatif yang perlu dipertimbangkan. Namun, pemilihan algoritma tetap harus mempertimbangkan karakteristik masalah, ukuran data, tipe target, dan evaluasi model.

3. Target tidak seimbang

Data tidak seimbang ialah dimana kondisi data memiliki proporsi yang berbeda cukup jauh misalkan kelas A memiliki proporsi 90% dari keseluruhan data sedangkan kelas B memiliki proporsi 10 % dari keseluruhan data. Data yang memiliki proporsi lebih banyak disebut kelas mayoritas sedangkan data yang memiliki proporsi lebih sedikit disebut kelas minoritas.

Salah satu teknik untuk mengatasi data yang tidak seimbang dapat menggunakan oversampling. Oversampling yang akan dibahas kali ini adalah SMOTE atau Synthetic Minority Over-sampling Technique. SMOTE adalah Teknik oversampling yang dimana synthetic / sintetik sample akan ditambahkan pada kelas minoritas. Algoritma SMOTE membantu mengatasi masalah overfitting yang disebabkan oleh Random Over Sampler.

BAB II

ENSIKLOPEDIA FUNGSI EDA

2.1 Pengecekan Struktur dan Kondisi Data

Fungsi	Library	Tujuan	Parameter/ atribut kunci	Contoh Output	Hubungan dengan EDA
df.head()	Pandas	Melihat beberapa data awal	n, axis	5 baris pertama	Memahami bentuk data
df.tail()	Pandas	Melihat data bagian akhir	n	5 baris terakhir	Memeriksa kondisi data akhir
df.shape	Pandas	Mengetahui ukuran dataset	shape	(1000, 8)	Mengetahui jumlah baris/kolom
df.columns	Pandas	Melihat nama kolom	-	Index nama kolom	Mengetahui fitur tersedia
df.dtypes	Pandas	Melihat tipe data	-	int64, object	Mengetahui tipe variabel
df.info()	Pandas	Melihat informasi dataset	verbose, memory_usage	Struktur + null	Mendeteksi masalah struktur
df.describe()	Pandas	Statistik deskriptif	include, percentiles	mean, std, min, max	Memahami distribusi numerik

df.memory_usage()	Pandas	Melihat penggunaan memori	index, deep	penggunaan byte	Mengevaluasi struktur dataset
df.select_dtypes()	Pandas	Memilih tipe kolom tertentu	include, exclude	Data numerik/kategorikal	Memisahkan jenis variabel
df.nunique()	Pandas	Menghitung nilai unik	axis, dropna	jumlah nilai unik	Mengetahui variasi data

2.2 Statistik dan Distribusi

Fungsi	Library	Tujuan	Parameter /atribut kunci	Contoh Output	Hubungan dengan EDA
df.mean()	Pandas	Menghitung rata-rata	axis, skipna	-	Mengetahui pusat data
df.median()	Pandas	Menghitung median	axis, skipna	-	Berguna ketika terdapat outlier
df.mode()	Pandas	Mencari modus	axis, dropna	nilai paling sering	Mengetahui nilai dominan
df.var()	Pandas	Menghitung variansi	axis, ddof	-	Mengukur penyebaran

df.std()	Pandas	Menghitung standar deviasi	axis, ddof	-	Mengukur variasi data
df.quantile()	Pandas	Menghitung kuantil	q, interpolation	Q1, Q2, Q3	Menganalisis distribusi
df.skew()	Pandas	Mengukur skewness	axis, skipna	-	Mendeteksi distribusi miring
df.kurt()	Pandas	Mengukur kurtosis	axis, skipna	-	Melihat bentuk distribusi/tail
df.corr()	Pandas	Menghitung korelasi	method, min_periods	matriks korelasi	Mendeteksi hubungan antarfitur
df.value_counts()	Pandas	Menghitung frekuensi nilai	normalize, dropna	frekuensi kategori	Melihat distribusi kategori

2.3 Missing Value dan Data Quality

Fungsi	Library	Tujuan	Parameter kunci	Contoh Output	Hubungan dengan EDA
df.isnull()	Pandas	Mendeteksi nilai kosong	-	True/False	Mencari missing value

df.isnull().sum())	Pandas	Menghitung missing value	axis	jumlah null	Mendeteksi masalah data
df.notnull()	Pandas	Mendeteksi data tidak kosong	-	True/False	Pemeriksaan kualitas data
df.dropna()	Pandas	Menghapus data kosong	axis, how	Data tanpa null	Cleaning berdasarkan hasil EDA
df.duplicated()	Pandas	Mendeteksi duplikat	subset, keep	True/False	Mendeteksi data ganda
df.drop_duplicates()	Pandas	Menghapus duplikat	subset, keep	Dataset bersih	Menangani masalah duplikasi

2.4 Visualisasi

Fungsi	Library	Tujuan	Parameter kunci	Contoh Output	Hubungan dengan EDA
plt.hist()	Matplotlib	Histogram distribusi	bins, density	Histogram	Melihat distribusi
plt.scatter()	Matplotlib	Scatter plot	x, y	Titik-titik data	Melihat hubungan dua variabel

plt.plot()	Matplotlib	Line plot	x, y	Grafik garis	Melihat tren
sns.boxplot()	Seaborn	Melihat distribusi & outlier	x, y	Boxplot	Mendeteksi outlier
sns.histplot()	Seaborn	Histogram	data, bins	Histogram	Melihat distribusi
sns.countplot()	Seaborn	Menghitung kategori	x, hue	Bar chart	Melihat imbalance
sns.heatmap()	Seaborn	Visualisasi matriks	data, annot	Heatmap	Mendeteksi korelasi
sns.pairplot()	Seaborn	Membandingkan banyak variabel	data, hue	Kumpulan scatter plot	Melihat pola antarfitur
sns.violinplot()	Seaborn	Melihat distribusi	x, y, hue	Violin plot	Melihat distribusi dan penyebaran
sns.jointplot()	Seaborn	Hubungan dua variabel	x, y, kind	Scatter + distribusi	Analisis hubungan variabel

2.5 Statistik Lanjutan dan Preprocessing untuk Eksplorasi

Fungsi	Library	Tujuan	Parameter kunci	Contoh Output	Hubungan dengan EDA
<code>scipy.stats.pearsonr()</code>	SciPy	Mengukur korelasi Pearson	x, y	correlation + p-value	Menguji hubungan linear
<code>scipy.stats.spearmanr()</code>	SciPy	Korelasi Spearman	a, b	correlation + p-value	Menguji hubungan monotonic
<code>scipy.stats.ttest_ind()</code>	SciPy	Membandingkan dua kelompok	a, b	t-statistic + p-value	Membandingkan distribusi kelompok
<code>scipy.stats.chi2_contingency()</code>	SciPy	Uji hubungan data kategorikal	observed, correction	chi-square + p-value	Menganalisis hubungan kategori